



# 연구 노트 3주차

▼ 2팀 : 20191467 이재형

✓ 연구 주제 : Adative data enginering Learning framework

✓ 3주차 Topic : Baseline model 검증 & 보상 함수 고찰




지난 2주차에 Baseline model로 설정한 Face Transformer을 바탕으로 목적함수와 task reward를 선정하였다. 이번 주차에는 Face Transforemr 모델을 활용하여 toy dataset에서의 성능을 평가하고, 모델의 범용성 및 효율성을 검증하였다. 또한, 2주차에 선정한 reward 함수에 대한 고찰을 진행하였다.

## Method

- **모델 설정** : Github의 Face Transformer 프로젝트[1]에서 ViT-P8S8 사전 훈련된 모델 다운로드하여 사용
- **데이터셋** : 테스트를 위하여 작은 규모의 토이 데이터셋 준비
  - ▼ Toy dataset : TNBC dataset[2]
    - TNBC 데이터셋은 삼중음성유방암(TNBC) 연구를 위해 특별히 마련된 상세한 세포 이미지 데이터를 포함하고 있다.
    - 이 데이터셋에는 정상 상피세포 및 근상피세포, 침윤성 암세포 등 유방 조직 및 암과 관련된 다양한 세포 유형이 포함되어 있다.
    - 데이터셋은 총 4022개의 주석이 달린 세포를 포함하는 50개의 이미지로 구성되어 있으며, TNBC의 세포 수준 연구에 자세한 자료를 제공한다.
- **모델 검증** : 모델을 데이터셋에 적용하고, 2주차에서 설정한 f1 score 사용
  - ▼ f1 score
    - F1 점수는 정밀도와 재현율의 조화평균으로, 모델의 분류 성능을 평가하는 데 사용됩니다. 이 점수는 0에서 1 사이의 값을 가지며, 1은 최고의 성능을 나타낸다.
    - f1스코어는 Segmentation작업에서 F1-점수는 모델이 예측한 픽셀이 실제로 얼마나 정확한지를 측정하는 지표이다.
    - 이는 정밀도(Precision)와 재현율(Recall)의 조화평균을 기반으로 하며, 각각 모델이 예측한 픽셀 중 실제와 일치하는 픽셀의 비율과 실제 픽셀 중 모델이 정확하게 예측한 픽셀의 비율을 나타냅니다. 이렇게 F1-점수는 세그멘테이션 모델의 성능을 종합적으로 평가하는 데 사용된다.

## Result




- **Predict**



- **GT[3]**

[TNBC\\_NucleiSegmentation.zip](#)





- 위의 사진은 TNBC cell segmentation Dataset으로 Binary segmentation Task를 수행하는 목적을 가지는 Dataset 이다.
- Reward의 개념으로 Cell을 추적할때마다 Reward를 제공하며 적은 량의 데이터셋(train - 94)개를 가지고 Test -data에 대해서 검출을 하는 경우에도 잘 추적하고 있음을 보여주었다.
- 다만 Reward의 벌칙으로 False - Positive에 대한 벌칙항을 높게 주어 학습이 조기 종료가되어 디테일한 부분까지 픽셀 segmentation 이 되지 않아 향후 하이퍼파라미터 수정을 할 예정이다.

## Reward 고찰

$$PQ = \text{mean}_{k \in K} \frac{\sum_{(p,g) \in TP_k} IoU(p, g)}{|TP_k| + \frac{1}{2}|FP_k| + \frac{1}{2}|FN_k|}$$

<https://arxiv.org/pdf/2302.08242>

- 위의 그림은 Panomatic(Semantic + instance) Segmentation에서 사용하는 Eval Function으로 이를 Task reward로 활용하여 아래의 식으로 리워드를 부여한다.

$$reward(y, k) = \left[ \sum_{(p,g) \in TP_k} IoU(p, g) \right] - w|FP_k|$$

<https://arxiv.org/pdf/2302.08242>

- Reward function으로는 PQ 평가 지표를 최대화 하기 위해 IOU가 최대가 되어야 하므로 IOU를 최대화 하고 각자 개인의 원하는 상황에 따라 다르지만 거짓 양성을 억제하기 위해 벌칙 항으로  $-w|FP_k|$ 항이 붙어 있음을 볼 수 있음.
- 우리와 같은 경우에는 f1-score를 지표로 삼으므로  $f1 - score = \frac{1}{precision} + \frac{1}{recall}$ 이고 이를 우리의 상황에 대입하면 적용하고자 하는 테스트에 적합한 리워드를 지정할 수 있다.

$$reward(y, k) = f1 - w * FP_k \\ (0 < w < 1)$$

- 위의 과정을 통해 설정한 reward function에 대해 고찰해보았다.
- 이 보상 함수는 거짓 양성(FP)의 수가 많을수록 보상을 크게 감소시킨다.
  - 그러므로 모델이 거짓 양성을 줄이는 방향으로 편향될 가능성이 존재한다.
  - 이는 특정 상황에서 모델이 보수적인 예측을 하게 만들어 재현율을 떨어뜨릴 수 있다.
- 위 보상 함수를 사용한다면, w의 값을 모델의 목표에 맞추어 신중하게 조정해야 할 것이다.
- 보상 함수를 선택할 때 목표하는 모델 성능의 균형을 고려해야 한다. 거짓 양성과 거짓 음성을 모두 고려하는 보상 함수 몇가지를 알아보았다.

### 1. F1-Score 및 벌칙 조합

$$reward(y, k) = F1 \text{ score} - w_1|FP| - w_2|FN|$$

여기서 w1과 w2는 거짓 양성과 거짓 음성에 대한 벌칙의 가중치이다. 이 방식은 모델이 정밀도와 재현율 사이의 균형을 유지한다.

### 2. 조정된 F1-Score

$$reward(y, k) = \frac{(1 + \beta^2) \cdot \text{precision} \cdot \text{recall}}{(\beta^2 \cdot \text{precision}) + \text{recall}} - w|FP|$$

beta값은 재현율이 정밀도에 비해 몇 배 더 중요한지를 결정한다.  $\beta > 1$ 일 때 재현율을 더 중요하게 평가하며, 이는 특히 FN을 더 크게 피하고자 할 때 유용하다.

### 3. IoU 기반 보상 함수

$$reward(y, k) = IoU - w|FP|$$

IoU (Intersection over Union)는 모델의 예측과 실제 값의 겹치는 정도를 측정하므로, 세그멘테이션에 특히 적합하다.

이 중에서 가장 모델의 목표와 맞는 함수를 선택하고, 실험을 통해 가중치 w1, w2, w를 적절히 조정하는 것이 중요하다. 실험을 통해 최적의 가중치를 찾아내는 과정도 필요할 것이다.

---

## Reference

- [1] [https://github.com/zhongyy/Face-Transformer#4-pretrained-models-and-test-models-on-lfw-sllfw-calfw-cplfw-talfw-cfp\\_fp-agedb](https://github.com/zhongyy/Face-Transformer#4-pretrained-models-and-test-models-on-lfw-sllfw-calfw-cplfw-talfw-cfp_fp-agedb)
- [2] <https://paperswithcode.com/dataset/tnbc>
- [3] <https://zenodo.org/records/1175282#.YMisCTZKgow>